Notas de Métodos estatísticos do Boletim de Saúde e Clima de Belém

CISC Belém – Centro de Informação em Saúde e Clima

Outubro de 2026

Resumo

Estas notas explicam os métodos da seção 2.3 (Método) do Boletim de Saúde e Clima de Belém 2026: a função de distribuição e sua inversa, o mapeamento quantílico usado para preencher lacunas, as anomalias e a decomposição sazonal, os limiares percentílicos, a regressão quantílica aditiva (QGAM), o modelo aditivo generalizado (GAM) dos diagramas de controle e o modelo de defasagem distribuída não linear (DLNM). Cada conceito aparece primeiro em palavras, depois em fórmula e, sempre que possível, com um exemplo numérico. Os termos técnicos são relembrados no texto e reunidos num glossário no final.

Sumário

Como ler estas notas **3**

1 Mapa dos métodos **3**

2 Conceitos básicos de probabilidade **3**

3 Função de distribuição e função quantil **5**

3.1 Função de distribuição acumulada 5

3.2 Inversa generalizada (função quantil) 5

3.3 O lema fundamental 6

3.4 Transformação integral de probabilidade 7

3.5 A versão empírica: estimando com dados 8

3.6 Quantis e transformações monótonas 10

4 Mapeamento quantílico **10**

4.1 O problema 10

4.2 Definição e algoritmo 11

4.3 Por que o método funciona 12

4.4 Comparação com a interpolação linear 12

4.5 Validação 13

4.6 Limitações 14

5 Anomalias, tendência e decomposição sazonal **14**

5.1 Normal climatológica e anomalia 14

5.2 Tendência por década 15

5.3 Decomposição sazonal 15

6 Limiares percentílicos e episódios **16**

6.1 P90 sazonal fixo 16

6.2 Episódios 16

7 Regressão quantílica e QGAM **17**

7.1 Por que modelar quantis e não a média 17

7.2 Que valor "resume melhor" os dados? 17

7.3 Regressão quantílica linear 18

7.4 QGAM: regressão quantílica com curvas 19

8 MLG, GAM e diagramas de controle **20**

8.1 Por que não usar a regressão linear comum para contagens 20

8.2 O modelo linear generalizado 21

8.3 Verossimilhança 22

8.4 Superdispersão 22

8.5 GAM: quando a relação é uma curva 22

8.6 O diagrama de controle do boletim 23

9 DLNM: efeitos não lineares e defasados **24**

9.1 Motivação 24

9.2 Modelo de defasagem distribuída 25

9.3 Base cruzada: as duas dimensões juntas 25

9.4 O modelo do boletim 26

9.5 Como ler os resultados 26

10 Índice de vulnerabilidade territorial **27**

11 Glossário **28**

12 Exercícios **29**

Referências **30**

Como ler estas notas

As notas usam cinco tipos de quadro:

- **Relembrando**: retoma um conceito básico de probabilidade, cálculo ou estatística antes de ele ser usado.
- **Em palavras**: traduz uma fórmula ou uma demonstração para linguagem comum.
- **Em Belém**: mostra como o método foi aplicado no boletim e quais números saíram dele.
- **Cuidado**: aponta limitações e erros comuns de interpretação.
- **Resumo da seção**: fecha as seções mais longas.

As demonstrações estão completas, mas cada uma vem acompanhada de uma explicação em palavras. Numa primeira leitura, é possível ler só as explicações e voltar às demonstrações depois.

1 Mapa dos métodos

O boletim responde a perguntas diferentes, e cada pergunta pede um método. A tabela mostra essa correspondência.

Pergunta do boletim	Método	Seção
Como preencher dias sem registro na estação?	Mapeamento quantílico	4
O mês foi mais quente que o normal? Há tendência?	Anomalias e decomposição sazonal	5
Hoje está anormalmente quente para a época?	P90 sazonal fixo e episódios	6
Os dias mais quentes estão ficando mais quentes?	Regressão quantílica aditiva (QGAM)	7
Os casos da semana estão acima do esperado?	GAM binomial negativo	8
O calor se associa a óbitos, e com que atraso?	DLNM quase-Poisson	9
Onde estão os territórios mais vulneráveis?	Índice de vulnerabilidade (IVT)	10

Antes dos métodos, a Seção 2 relembra os conceitos básicos de probabilidade, e a Seção 3 apresenta a função de distribuição e a função quantil. Essas duas ideias sustentam três métodos ao mesmo tempo: o mapeamento quantílico, os limiares percentílicos e a regressão quantílica.

2 Conceitos básicos de probabilidade

Esta seção é uma revisão rápida. Quem já domina os conceitos pode ir direto à Seção 3.

Variável aleatória. É uma quantidade cujo valor depende do acaso e só é conhecido depois de observado. A temperatura máxima de amanhã em Belém e o número de óbitos de amanhã são variáveis aleatórias. Usam-se letras maiúsculas (X, Y) para a variável e minúsculas (x, y) para um valor observado dela.

Discreta ou contínua. Uma variável é *discreta* quando só assume valores separados, como contagens: 0, 1, 2 óbitos. É *contínua* quando pode assumir qualquer valor num intervalo, como a temperatura: 32,47 °C. A precipitação diária é um caso misto: tem uma chance positiva de ser exatamente zero (dia seco) e, nos dias com chuva, varia continuamente.

Distribuição. É a regra que diz quais valores a variável pode assumir e com que probabilidade. Numa variável discreta, a distribuição dá $\mathbb{P}(X = x)$ para cada valor. Numa variável contínua, a probabilidade de um valor exato é zero, e a distribuição é descrita por uma *densidade* $f(x)$: a área sob a curva de f entre a e b é a probabilidade de X cair entre a e b.

Esperança (média). É o valor médio que a variável teria se o experimento fosse repetido infinitas vezes, denotado $\mathbb{E}(X)$ ou μ. Numa variável discreta, $\mathbb{E}(X) = \sum_x x\,\mathbb{P}(X = x)$.

Variância e desvio-padrão. A variância mede quanto a variável se espalha em torno da média:

$$\mathrm{Var}(X) = \mathbb{E}\big[(X - \mu)^2\big].$$

O desvio-padrão $\sigma = \sqrt{\mathrm{Var}(X)}$ está na mesma unidade da variável (°C, por exemplo) e por isso é mais fácil de interpretar.

Correlação. Mede o quanto duas variáveis variam juntas de forma linear. Vai de -1 a 1. Valores perto de 1 indicam que, quando uma está alta, a outra também tende a estar. Valores perto de 0 indicam pouca relação linear.

População, amostra e estimador. A *população* (ou o modelo) tem características desconhecidas, como a verdadeira média μ. A *amostra* são os dados observados. Um *estimador* é uma regra que usa a amostra para aproximar a característica desconhecida, como a média amostral $\bar{x}$ aproxima μ.

Viés e consistência. Um estimador é *não viesado* quando, em média ao longo de muitas amostras, acerta o valor verdadeiro. É *consistente* quando fica cada vez mais próximo do valor verdadeiro à medida que a amostra cresce.

Quantil (ideia intuitiva). O quantil de ordem 0,9 é o valor que deixa 90% dos dados abaixo e 10% acima. Também se chama *percentil 90* ou P90. A mediana é o quantil de ordem 0,5. A Seção 3 dá a definição exata.

3 Função de distribuição e função quantil

3.1 Função de distribuição acumulada

Definição 3.1. A *função de distribuição acumulada* (FDA) de uma variável aleatória X é

$$F(x) = \mathbb{P}(X \leq x), \qquad x \in \mathbb{R}.$$

Em palavras

$F(x)$ responde à pergunta: *qual é a probabilidade de a variável ficar até o valor x?* Se X é a temperatura máxima de um dia de agosto em Belém e $F(33) = 0{,}70$, então 70% dos dias de agosto têm máxima de até 33 °C. A palavra "acumulada" indica que a função soma toda a probabilidade à esquerda de x.

Toda FDA tem três propriedades (Casella & Berger, 2002, Teorema 1.5.3):

(i) **é não decrescente**: se $x_1 < x_2$, então $F(x_1) \leq F(x_2)$. Ao andar para a direita, só se acumula mais probabilidade, nunca menos;

(ii) **vai de 0 a 1**: $F(x) \to 0$ quando $x \to -\infty$ e $F(x) \to 1$ quando $x \to \infty$. Bem à esquerda não há probabilidade acumulada; bem à direita está toda;

(iii) **é contínua à direita**: $\lim_{h \downarrow 0} F(x+h) = F(x)$.

Relembrando: continuidade à direita

Uma função é *contínua à direita* em x quando, ao se aproximar de x vindo da direita (por valores um pouco maiores), o valor da função se aproxima de $F(x)$. Na FDA isso acontece por causa do sinal "$\leq$" na definição: o ponto x já está incluído em $F(x)$. Quando há um salto, o valor da função no ponto é o valor *de cima* do salto.

A FDA pode ter dois tipos de irregularidade:

- **saltos**, quando há probabilidade concentrada num ponto, como o zero da precipitação;
- **trechos planos**, quando um intervalo de valores não tem probabilidade nenhuma.

Nos dois casos, F não é uma correspondência um a um entre valores e probabilidades. Por isso a inversa comum não existe, e é preciso uma definição mais geral.

3.2 Inversa generalizada (função quantil)

A FDA vai *do valor para a probabilidade*: dado x, devolve $F(x)$. A função quantil faz o caminho de volta: *da probabilidade para o valor*.

Relembrando: ínfimo

O *ínfimo* de um conjunto de números é o maior número que é menor ou igual a todos os elementos do conjunto. Na prática, é "o menor valor do conjunto", com uma ressalva: ele pode não pertencer ao conjunto. O ínfimo do intervalo $(2, 5]$ é 2, embora 2 não esteja no intervalo. O ínfimo de $[2, 5]$ também é 2, e nesse caso ele é o mínimo.

Definição 3.2 (Função quantil)**.** Para $u \in (0,1)$, a *inversa generalizada* de F é

$$\boxed{F^{-1}(u) = \inf\{\, x \in \mathbb{R} : F(x) \geq u \,\}}$$

O número $\xi_u = F^{-1}(u)$ é o *quantil de ordem* u de X. Em particular, $F^{-1}(0{,}5)$ é a mediana e $F^{-1}(0{,}9)$ é o percentil 90 (P90).

Em palavras

$F^{-1}(u)$ é o *menor valor x em que a probabilidade acumulada atinge pelo menos u*. Para achar o P90, percorre-se o eixo dos valores da esquerda para a direita e para-se no primeiro ponto em que F chega a 0,90.
Pela continuidade à direita, o conjunto $\{x : F(x) \geq u\}$ inclui sua extremidade esquerda. Então o ínfimo é de fato um mínimo: o quantil é um valor que a FDA alcança.

Três situações ajudam a fixar a definição:

- Se F é contínua e estritamente crescente (sem saltos e sem trechos planos), F^{-1} é a inversa comum.
- Num *salto* de F no ponto x_0, todas as probabilidades u cobertas pelo salto têm o mesmo quantil x_0.
- Num *trecho plano* de F na altura u, o ínfimo escolhe a extremidade esquerda do trecho.

Exemplo 3.3 (Variável com saltos)**.** Seja X igual a 1 se chove e 0 se não chove, com $\mathbb{P}(X = 1) = 0{,}3$. A FDA vale 0 antes de zero, salta para 0,7 em $x = 0$ e para 1 em $x = 1$. Logo:

- para u entre 0 e 0,7, o primeiro ponto em que F alcança u é $x = 0$, e então $F^{-1}(u) = 0$;
- para u acima de 0,7, só em $x = 1$ a FDA alcança u, e então $F^{-1}(u) = 1$.

3.3 O lema fundamental

O resultado a seguir parece técnico, mas todo o resto das notas depende dele.

Lema 3.4. *Para qualquer FDA F, todo $u \in (0,1)$ e todo $x \in \mathbb{R}$,*

$$F^{-1}(u) \leq x \iff u \leq F(x).$$

Em palavras

As duas frases dizem a mesma coisa: "o quantil de ordem u está à esquerda de x" e "até x já se acumulou probabilidade u". Por exemplo, "o P90 é no máximo 34 °C" equivale a "até 34 °C já estão pelo menos 90% dos dias".

Demonstração. ($\Leftarrow$) Se $u \leq F(x)$, então x pertence ao conjunto $\{y : F(y) \geq u\}$. O ínfimo de um conjunto é menor ou igual a qualquer elemento dele, logo $F^{-1}(u) \leq x$.

($\Rightarrow$) Seja $\xi = F^{-1}(u)$. Pela definição de ínfimo, existem pontos y_n do conjunto que se aproximam de ξ pela direita, com $F(y_n) \geq u$. Pela continuidade à direita, $F(\xi) = \lim F(y_n) \geq u$. Se $\xi \leq x$, como F é não decrescente, $F(x) \geq F(\xi) \geq u$. □

Negando os dois lados do lema, obtém-se uma forma equivalente que será usada adiante:

$$x < F^{-1}(u) \iff F(x) < u. \tag{1}$$

3.4 Transformação integral de probabilidade

Relembrando: distribuição uniforme

Uma variável U tem distribuição *uniforme* entre 0 e 1, escrita $U \sim \mathcal{U}(0,1)$, quando todos os valores do intervalo são igualmente prováveis. Sua FDA é $\mathbb{P}(U \leq u) = u$: a chance de cair até 0,3 é 0,3, a chance de cair até 0,9 é 0,9.

Teorema 3.5 (Transformação integral de probabilidade; Casella & Berger, 2002, Teorema 2.1.10)**.** *Se X tem FDA F* ***contínua****, então*

$$U = F(X) \sim \mathcal{U}(0,1).$$

Em palavras

Troque cada temperatura pela sua *posição na distribuição*: um dia no P10 vira 0,10, um dia na mediana vira 0,50, um dia no P90 vira 0,90. O teorema diz que essas posições se espalham de modo uniforme entre 0 e 1. Faz sentido: por definição, 10% dos dias estão abaixo do P10, 50% abaixo da mediana, 90% abaixo do P90. É exatamente o comportamento de uma uniforme.

Demonstração. Seja $u \in (0,1)$. Por (1), os eventos $\{F(X) < u\}$ e $\{X < F^{-1}(u)\}$ são iguais. Então

$$\mathbb{P}(F(X) < u) = \mathbb{P}\big(X < F^{-1}(u)\big) = F\big(F^{-1}(u)\big) = u.$$

A segunda igualdade usa a continuidade de F: sem saltos, a probabilidade de "menor que" é igual à de "menor ou igual". A terceira vale porque uma F contínua passa por todos os valores entre 0 e 1, e o quantil $F^{-1}(u)$ é justamente um ponto onde ela vale u. Como $\mathbb{P}(F(X) < u) = u$ para todo u, também $\mathbb{P}(F(X) \leq u) = u$, que é a FDA da uniforme. □

Teorema 3.6 (Método da inversa)**.** *Se $U \sim \mathcal{U}(0,1)$ e F é* ***qualquer*** *FDA, então*

$$F^{-1}(U) \sim F.$$

Em palavras

É o caminho de volta do teorema anterior. Sorteie uma posição U ao acaso entre 0 e 1 e procure o valor que ocupa essa posição na distribuição F. O valor obtido tem distribuição F. É assim que os computadores geram números aleatórios de qualquer distribuição a partir de números uniformes.

Demonstração. Pelo Lema 3.4, os eventos $\{F^{-1}(U) \leq x\}$ e $\{U \leq F(x)\}$ são iguais. Logo

$$\mathbb{P}\big(F^{-1}(U) \leq x\big) = \mathbb{P}\big(U \leq F(x)\big) = F(x).$$

A última igualdade é a FDA da uniforme avaliada em $F(x)$. □

Exemplo 3.7 (Gerando valores de uma exponencial)**.** A distribuição exponencial com média 1 tem FDA $F(x) = 1 - e^{-x}$ para $x \geq 0$. Resolvendo $u = 1 - e^{-x}$ em x, obtém-se $F^{-1}(u) = -\ln(1-u)$. Se o computador sorteia $U = 0{,}5$, o valor gerado é $-\ln(0{,}5) \approx 0{,}693$, que é a mediana dessa exponencial.

Note a diferença entre os dois teoremas: o Teorema 3.6 vale para qualquer F, inclusive com saltos; o Teorema 3.5 *exige* que F seja contínua.

Exemplo 3.8 (O Teorema 3.5 falha quando há saltos)**.** Na variável chuva/não chuva do exemplo anterior, $F(X)$ só assume dois valores: 0,7 (quando não chove, com probabilidade 0,7) e 1 (quando chove, com probabilidade 0,3). Isso não é uma uniforme. A consequência prática para a precipitação aparece na Seção 4.6.

3.5 A versão empírica: estimando com dados

Na prática, a FDA verdadeira é desconhecida. Ela é estimada a partir da amostra $X_1, \ldots, X_n$.

Relembrando: função indicadora

A *função indicadora* $\mathbb{I}(A)$ vale 1 quando a condição A é verdadeira e 0 quando é falsa. Somar indicadoras é uma forma compacta de *contar* quantas observações satisfazem uma condição.

Definição 3.9. A *função de distribuição empírica* é

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^{n} \mathbb{I}(X_i \leq x).$$

Em palavras

$\hat{F}_n(x)$ é a *proporção de observações menores ou iguais a* x. É a FDA "dos dados".

Exemplo 3.10. Considere as temperaturas máximas de cinco dias: 31,2; 32,0; 32,0; 33,5; 34,1 °C.

- $\hat{F}_5(31{,}0) = 0/5 = 0$: nenhuma observação é menor ou igual a 31,0.
- $\hat{F}_5(32{,}0) = 3/5 = 0{,}6$: três observações são menores ou iguais a 32,0.
- $\hat{F}_5(33{,}0) = 3/5 = 0{,}6$: entre 32,0 e 33,5 a função fica plana.
- $\hat{F}_5(34{,}1) = 5/5 = 1$.

A mediana empírica é $\hat{F}_5^{-1}(0{,}5)$: o primeiro valor em que a proporção chega a 0,5 é 32,0 °C (em 31,2 ela é só 0,2). O quantil de ordem 0,7 é 33,5 °C, onde a proporção passa de 0,6 para 0,8.

A função empírica é uma *escada*: sobe $1/n$ em cada observação (ou k/n quando k observações empatam). Por isso o quantil empírico é sempre calculado pela inversa generalizada.

Para cada x fixo, contar quantas observações ficam até x é como contar sucessos em n tentativas com probabilidade $F(x)$: $n\hat{F}_n(x)$ tem distribuição binomial. Daí resulta que $\hat{F}_n(x)$ é não viesado e consistente. O resultado mais forte é o seguinte.

Teorema 3.11 (Glivenko–Cantelli)**.** *Se* $X_1, X_2, \ldots$ *são independentes e têm a mesma FDA* F*, então*

$$\sup_{x \in \mathbb{R}} \left| \hat{F}_n(x) - F(x) \right| \xrightarrow{q.c.} 0.$$

Em palavras

A maior distância entre a escada dos dados e a FDA verdadeira, em qualquer ponto do eixo, tende a zero quando a amostra cresce. "q.c." significa *quase certamente*: isso acontece com probabilidade 1. Este teorema é a garantia de que usar a função empírica no lugar da verdadeira funciona quando há dados suficientes.

Quantis amostrais. A inversa generalizada da escada sempre devolve uma das observações.

Relembrando: estatísticas de ordem

Ordenando a amostra do menor para o maior valor, obtêm-se as *estatísticas de ordem* $X_{(1)} \le X_{(2)} \le \cdots \le X_{(n)}$. $X_{(1)}$ é o mínimo e $X_{(n)}$ é o máximo.

Os programas estatísticos suavizam o resultado interpolando entre duas estatísticas de ordem vizinhas. Hyndman & Fan (1996) escreveram as regras mais usadas numa forma única:

$$\hat{\xi}_u = (1-\gamma)\, X_{(j)} + \gamma\, X_{(j+1)}, \qquad j = \lfloor nu + m \rfloor, \qquad \gamma = nu + m - j,$$

em que $\lfloor \cdot \rfloor$ é a parte inteira e m define o tipo:

- **tipo 7** (padrão da função `quantile` do R): $m = 1 - u$;
- **tipo 8** (recomendado por Hyndman & Fan, aproximadamente não viesado para a mediana em qualquer distribuição): $m = (u+1)/3$.

Exemplo 3.12 (Calculando o P90 de sete dias)**.** Amostra ordenada: 30,8; 31,5; 32,0; 32,4; 33,1; 33,9; 34,6 °C. Aqui $n = 7$ e $u = 0{,}9$, então $nu = 6{,}3$.

- **Tipo 7**: $m = 0{,}1$, $nu + m = 6{,}4$, $j = 6$, $\gamma = 0{,}4$.
  $\hat{\xi}_{0{,}9} = 0{,}6 \times 33{,}9 + 0{,}4 \times 34{,}6 = 34{,}18$ °C.
- **Tipo 8**: $m = 1{,}9/3 \approx 0{,}633$, $nu + m \approx 6{,}933$, $j = 6$, $\gamma \approx 0{,}933$.
  $\hat{\xi}_{0{,}9} \approx 0{,}067 \times 33{,}9 + 0{,}933 \times 34{,}6 \approx 34{,}55$ °C.

Com poucos dados, a regra muda o P90 em quase 0,4 °C. Com centenas de observações, a diferença fica pequena. O boletim usa o tipo 8.

Por que os quantis extremos são imprecisos. Se F tem densidade f positiva no quantil ξ_u, vale aproximadamente, para n grande,

$$\hat{\xi}_u \approx \mathcal{N}\left(\xi_u,\ \frac{u(1-u)}{n\, f(\xi_u)^2}\right) \tag{2}$$

(Serfling, 1980).

Em palavras

O quantil amostral tem distribuição aproximadamente normal, centrada no quantil verdadeiro. A variância depende de $f(\xi_u)$, a *densidade* no quantil, isto é, de quantos dados costumam cair perto dele. No centro da distribuição há muitos dados, e a estimativa é precisa. Na cauda há poucos, $f(\xi_u)$ é pequena, e a variância cresce.

Exemplo 3.13. Para uma variável normal com desvio-padrão de 1 °C e observações independentes:

- com $n = 30$, o erro-padrão da mediana é cerca de 0,23 °C e o do P90, cerca de 0,31 °C;
- o erro-padrão do P99 é quase três vezes o da mediana;
- com $n = 930$, o erro-padrão do P90 cai para cerca de 0,06 °C.

Na prática, dias vizinhos são correlacionados, e a precisão real é um pouco menor. Mesmo assim, o exemplo mostra por que a Seção 6 usa uma janela de 31 dias para estimar o P90.

3.6 Quantis e transformações monótonas

Relembrando: função monótona

Uma função h é *não decrescente* (ou monótona crescente) quando preserva a ordem: se $a \leq b$, então $h(a) \leq h(b)$. A conversão de °C para °F, $h(c) = 1{,}8c + 32$, é um exemplo.

Proposição 3.14. *Se h é contínua e não decrescente, então*

$$F^{-1}_{h(X)}(u) = h\big(F^{-1}_X(u)\big).$$

Em palavras

Transformar e depois calcular o quantil dá o mesmo que calcular o quantil e depois transformar. O P90 em °F é a conversão do P90 em °C. A razão é simples: uma transformação crescente não muda a ordem dos dados, e o quantil só depende da ordem.
A média não tem essa propriedade quando a transformação não é linear: em geral, a média de X^2 é diferente do quadrado da média de X. Esta propriedade dos quantis reaparece no mapeamento quantílico e na regressão quantílica.

Resumo da seção

- A FDA vai do valor para a probabilidade; a função quantil $F^{-1}(u) = \inf\{x : F(x) \geq u\}$ vai da probabilidade para o valor e existe para qualquer distribuição.
- O Lema 3.4 liga as duas: $F^{-1}(u) \leq x$ equivale a $u \leq F(x)$.
- Dele saem dois resultados: as posições $F(X)$ são uniformes quando F é contínua, e $F^{-1}(U)$ tem distribuição F para qualquer F.
- Na prática usam-se a FDA empírica e os quantis amostrais, que são menos precisos nas caudas.

4 Mapeamento quantílico

4.1 O problema

Em Belém

A estação automática do INMET em Belém (A201) é a referência local, mas tem dias sem registro: 101 dias de temperatura máxima entre 1990 e 2025 e cerca de 120 noites de mínima noturna entre 2015 e 2025. O NASA POWER, uma base que combina satélite e modelos atmosféricos, não tem lacunas. Mas cada valor representa uma área de cerca de 50 km que mistura cidade, rio e floresta. Por isso tende a ter média e variabilidade diferentes das da estação.

Há três opções para preencher as lacunas:

1. **Copiar o NASA POWER**: levaria o erro sistemático dele para a série.
2. **Interpolar linearmente** entre os dias vizinhos: reduz a variabilidade e apaga extremos (Seção 4.4).

3. **Mapeamento quantílico** (Panofsky & Brier, 1968; Gudmundsson et al., 2012): usa o NASA POWER, mas corrige a distribuição inteira para que fique igual à da estação.

4.2 Definição e algoritmo

Sejam X a variável da fonte auxiliar (NASA POWER) e Y a variável da referência (estação), com FDAs F_X e F_Y.

Definição 4.1. O *mapeamento quantílico* é a transformação

$$\boxed{T(x) = F_Y^{-1}\big(F_X(x)\big)}$$

Em palavras

A ideia é a de um ranking. Pense em duas turmas que fizeram provas diferentes, uma mais difícil que a outra. Para comparar um aluno da turma A com a turma B, não se compara a nota, mas a *posição*: o aluno que ficou no top 20% da turma A corresponde ao aluno que ficou no top 20% da turma B.
O mapeamento quantílico faz o mesmo com as temperaturas, em dois passos:

1. $F_X(x)$: qual é a posição do valor x na distribuição do NASA POWER?
2. $F_Y^{-1}(\cdot)$: qual valor ocupa essa mesma posição na distribuição da estação?

Algoritmo com dados.

1. **Calibração.** Selecionar o período em que as duas séries têm dado e calcular as FDAs empíricas $\hat{F}_X$ e $\hat{F}_Y$.
2. **Posição.** Num dia sem registro na estação, calcular $u = \hat{F}_X(x)$ com o valor x do NASA POWER.
3. **Valor na referência.** Calcular $\tilde{y} = \hat{F}_Y^{-1}(u)$, interpolando entre estatísticas de ordem.
4. **Validação.** Esconder dias observados, preenchê-los e medir o erro (Seção 4.5).

Exemplo 4.2 (Ilustrativo, com dez dias de calibração)**.** Suponha dez dias em que as duas fontes têm dado. Valores ordenados:

Posição	1	2	3	4	5	6	7	8	9	10
NASA POWER (°C)	30,1	30,5	30,8	31,0	31,2	31,5	31,7	32,0	32,3	32,9
Estação (°C)	30,9	31,6	32,0	32,4	32,8	33,1	33,5	33,9	34,4	35,2

Num dia sem registro, o NASA POWER marca 32,0 °C.

1. Posição: 32,0 °C é o 8º de 10 valores do NASA POWER, então $u = \hat{F}_X(32{,}0) = 8/10 = 0{,}8$.
2. Valor: o primeiro valor da estação em que a proporção acumulada chega a 0,8 é o 8º, 33,9 °C.

O dia recebe $\tilde{y} = 33{,}9$ °C. Neste exemplo, a estação é sistematicamente cerca de 1,5 °C mais quente que o NASA POWER, e o método corrige isso automaticamente, sem que seja preciso estimar a diferença. Com séries longas, a interpolação entre estatísticas de ordem suaviza o resultado.

4.3 Por que o método funciona

Proposição 4.3. *Se F_X é contínua, então $T(X) = F_Y^{-1}(F_X(X))$ tem FDA F_Y.*

Demonstração. Pelo Teorema 3.5, a posição $U = F_X(X)$ é uniforme. Pelo Teorema 3.6, aplicar F_Y^{-1} a uma uniforme produz a distribuição F_Y. □

Em palavras

A prova tem duas linhas porque o trabalho já foi feito na Seção 3. O primeiro passo transforma os valores do NASA POWER em posições uniformes; o segundo transforma posições uniformes em valores com a distribuição da estação. A consequência é forte: **os valores preenchidos têm a mesma distribuição da estação**, com a mesma média, a mesma variabilidade e as mesmas caudas. O erro sistemático do NASA POWER, tanto de nível (mais frio ou mais quente) quanto de escala (mais ou menos variável), desaparece.

O método tem ainda duas propriedades:

(a) **Preserva a ordem dos dias.** T é crescente. Se o NASA POWER indica que o dia s foi mais quente que o dia t, os valores preenchidos mantêm essa ordem. A sequência de dias quentes e frios dentro de uma lacuna vem do NASA POWER.

(b) **É a única transformação desse tipo.** Pode-se mostrar que, com F_X contínua, nenhuma outra transformação crescente leva a distribuição do NASA POWER na da estação.

Pela Proposição 3.14, o mapeamento leva o quantil u do NASA POWER exatamente ao quantil u da estação. Um dia acima do P90 do NASA POWER vira um dia acima do P90 da estação. É isso que torna o método adequado para contar dias e episódios acima de limiares, que é o uso principal no boletim.

4.4 Comparação com a interpolação linear

A interpolação linear liga com uma reta os dois dias observados nas bordas da lacuna, Y_a e Y_b. Num dia intermediário, com peso w entre 0 e 1 (por exemplo, $w = 1/2$ no meio da lacuna),

$$\tilde{Y} = (1 - w)\, Y_a + w\, Y_b.$$

Relembrando: variância de uma combinação

Para duas variáveis com a mesma variância σ^2 e correlação ρ,

$$\mathrm{Var}(aY_a + bY_b) = a^2\sigma^2 + b^2\sigma^2 + 2ab\,\rho\,\sigma^2.$$

Aplicando com $a = 1 - w$ e $b = w$,

$$\mathrm{Var}(\tilde{Y}) = \sigma^2\big[(1-w)^2 + w^2 + 2w(1-w)\rho\big] \le \sigma^2,$$

com igualdade só quando $\rho = 1$. No meio da lacuna, $\mathrm{Var}(\tilde{Y}) = \sigma^2(1+\rho)/2$.

Em palavras

Uma média de dois dias varia menos que um dia isolado, porque altos e baixos se compensam. Por isso a interpolação **encolhe a variabilidade**: os dias preenchidos ficam "mornos" demais e os extremos desaparecem. Com $\rho = 0{,}6$, o desvio-padrão no meio da lacuna cai cerca de 11%.

Em Belém

Na validação da temperatura máxima, a interpolação linear reduziu o desvio-padrão da série preenchida em 10% a 17%. O mapeamento quantílico, por construção, preserva a variabilidade da estação. Na temperatura máxima, o valor mapeado foi ainda ajustado nas bordas de cada lacuna pela interpolação dos resíduos (estação menos mapeado) dos dias vizinhos, para evitar saltos na emenda.

4.5 Validação

Não é possível medir o erro nos dias que realmente faltam, porque não se sabe o valor verdadeiro. A solução é *simular lacunas*: escolhem-se blocos de dias que têm dado, escondem-se os valores, preenchem-se esses dias e compara-se o preenchido com o observado.

Relembrando: erro absoluto médio

O *erro absoluto médio* (MAE) é a média das distâncias entre o valor verdadeiro e o estimado, sem sinal:

$$\mathrm{MAE} = \frac{1}{k} \sum_{i=1}^{k} |y_i - \tilde{y}_i|.$$

Está na mesma unidade da variável. Um MAE de 0,5 °C significa que, em média, cada valor preenchido erra meio grau, para cima ou para baixo.

Os blocos devem ter os tamanhos das lacunas reais (3, 7, 15, 30 dias), porque o desempenho da interpolação piora quando a lacuna aumenta.

Em Belém

Série	Método escolhido	MAE (validação)
Temperatura máxima (101 dias, 1990–2025)	Mapeamento quantílico	0,87 a 1,01 °C
Mínima noturna (120 noites, 2015–2025)	Mapeamento quantílico	0,53 a 0,56 °C
comparação: interpolação linear		0,54 a 0,61 °C

Em 2026, só duas noites isoladas foram preenchidas por interpolação linear, e nenhum valor foi gerado depois de 31/08.

4.6 Limitações

Cuidado

1. **Corrige a distribuição, não cada dia.** O método garante que o *conjunto* de valores preenchidos tem a forma certa. A precisão de cada dia isolado depende da correlação diária entre as fontes. Na mínima noturna, essa correlação é cerca de 0,45, e uma noite preenchida isolada pode errar bastante.
2. **Não ultrapassa o histórico.** Se o NASA POWER marcar um valor maior que todos os do período de calibração, a posição será $\hat{F}_X = 1$, e o valor preenchido será o máximo já observado na estação. Para preencher lacunas isso é aceitável. Para projetar extremos futuros, seria preciso modelar a cauda com distribuições próprias para extremos (GEV ou Pareto generalizada).
3. **Supõe que a relação entre as fontes é estável.** Uma troca de sensor, mudanças no entorno urbano da estação ou uma nova versão do NASA POWER podem alterar essa relação.
4. **Exige variável contínua.** A Proposição 4.3 usa o Teorema 3.5, que pede F_X contínua. A precipitação tem uma chance positiva de ser exatamente zero, e as posições $F_X(X)$ não são uniformes. Nesse caso, trata-se separadamente a *ocorrência* de chuva e a *quantidade* nos dias chuvosos. É pelo mesmo motivo que o limiar de chuva extrema do boletim é o P95 *dos dias com chuva*.

5 Anomalias, tendência e decomposição sazonal

5.1 Normal climatológica e anomalia

Definição 5.1. A *normal climatológica* de um mês m é a média desse mês num período de referência de 30 anos, aqui 1991–2020:

$$\bar{x}_m = \frac{1}{30} \sum_{a=1991}^{2020} x_{a,m}.$$

A *anomalia* do mês m do ano a é a diferença em relação à normal:

$$A_{a,m} = x_{a,m} - \bar{x}_m.$$

Em palavras

A normal é "o que se espera" para aquele mês. A anomalia diz quanto o mês ficou acima (positiva) ou abaixo (negativa) do esperado. Usam-se 30 anos porque é um período longo o bastante para que anos atípicos não distorçam a média; é o padrão da Organização Meteorológica Mundial.
Subtrair a normal remove o ciclo anual. Sem isso, não faria sentido comparar março com outubro: outubro é naturalmente mais quente. Uma anomalia de $+0{,}8$ °C em março e outra de $+0{,}8$ °C em outubro, por outro lado, são diretamente comparáveis.

5.2 Tendência por década

Ajusta-se uma reta às anomalias ao longo do tempo:

$$A_t = \gamma_0 + \gamma_1 \, t + \varepsilon_t, \qquad t \text{ em anos.}$$

Relembrando: regressão linear por mínimos quadrados

A reta é escolhida de modo a minimizar a soma dos quadrados das distâncias verticais entre os pontos e a reta, $\sum_t (A_t - \gamma_0 - \gamma_1 t)^2$. O coeficiente γ_1 é a inclinação: quanto a anomalia muda, em média, por ano. O termo ε_t é o erro, a parte que a reta não explica.

Como a inclinação é por ano, o boletim reporta $10\,\hat{\gamma}_1$, em °C por década, que é uma escala mais fácil de ler.

Cuidado

Autocorrelação. Em séries climáticas, um mês quente tende a ser seguido de outro mês quente: os erros ε_t de meses vizinhos são correlacionados. Isso é a *autocorrelação*. O erro-padrão usual da regressão supõe erros independentes e, com autocorrelação positiva, *subestima* a incerteza. Na prática, a tendência parece mais "significativa" do que é. Para testá-la, usam-se erros-padrão corrigidos (Newey–West) ou modelos que incluem a autocorrelação nos erros, como os modelos AR (Morettin & Toloi, 2006).

5.3 Decomposição sazonal

Uma série mensal pode ser vista como a soma de três partes:

$$X_t = T_t + S_t + \varepsilon_t.$$

- T_t é a **tendência**: o movimento lento, de anos.
- S_t é a **sazonalidade**: o padrão que se repete a cada 12 meses. Os 12 efeitos mensais somam zero, para que a sazonalidade só redistribua valores ao longo do ano, sem mudar o nível.
- ε_t é o **componente irregular**: o que sobra.

Na decomposição clássica, os três componentes são obtidos em sequência:

1. A tendência é estimada por uma *média móvel centrada* de 12 meses. Cada valor é substituído pela média dos meses em volta dele, o que elimina a sazonalidade, porque cada média contém um ano inteiro. Com 12 meses não há um mês central, e por isso se usam 13 meses com peso pela metade nos dois extremos (média móvel "2×12").
2. A sazonalidade de cada mês é a média, entre os anos, da diferença $X_t - \hat{T}_t$ naquele mês, centrada para somar zero.
3. O irregular é o que sobra: $\hat{\varepsilon}_t = X_t - \hat{T}_t - \hat{S}_t$.

Em Belém

O ciclo anual de Belém é marcado pela chuva, mais do que pela temperatura. O "inverno amazônico" (dezembro a maio) é chuvoso e um pouco mais fresco; o segundo semestre é mais seco e mais quente. A amplitude anual da temperatura média é de poucos graus, e por isso anomalias de alguns décimos de grau já são informativas.

6 Limiares percentílicos e episódios

6.1 P90 sazonal fixo

O problema de um limiar único. Se o limiar de calor fosse o P90 do ano todo, quase todos os dias "extremos" cairiam no segundo semestre, que é naturalmente mais quente. Um dia de março muito quente para março nunca seria detectado. O limiar sazonal compara cada dia com dias *da mesma época do ano*.

Definição 6.1. Para o dia do ano d (de 1 a 365), o P90 sazonal é

$$P_{90}(d) = \hat{F}_d^{-1}(0{,}90),$$

em que $\hat{F}_d$ é a FDA empírica de todas as temperaturas observadas nos 15 dias antes e nos 15 dias depois de d, em todos os anos de 1991 a 2020:

$$\mathcal{J}_d = \{\, x_{a,d'} : |d' - d| \le 15,\ a = 1991, \ldots, 2020 \,\}.$$

Em palavras

Para saber se 15 de março foi anormalmente quente, juntam-se todas as temperaturas de 28 de fevereiro a 30 de março dos 30 anos da normal e calcula-se o valor que só 10% delas superam. Esse é o P90 de 15 de março.

Por que a janela de ± 15 dias. Com um único dia do ano, haveria no máximo 30 valores (um por ano) para estimar cada P90. A Seção 3 mostrou que quantis de cauda estimados com poucos dados são imprecisos. A janela de 31 dias leva a até $31 \times 30 = 930$ valores. O boletim exige ainda pelo menos 100 valores e 10 anos com dado para calcular o limiar, e usa o quantil amostral do tipo 8.

Por que "fixo". O limiar é calculado só com a normal 1991–2020 e não muda quando novos anos entram na série. Assim, um aumento no número de dias acima do P90 em anos recentes indica aquecimento real em relação à referência, e não uma mudança na régua.

6.2 Episódios

Um dia está num *episódio de calor* quando faz parte de uma sequência de pelo menos três dias consecutivos acima do P90. O indicador de que uma sequência de três dias termina no dia t é

$$E_t = \mathbb{I}\left(\bigcap_{j=0}^{2} \{ x_{t-j} > P_{90}(d_{t-j}) \} \right).$$

Em palavras

O símbolo $\bigcap$ significa "e": $E_t = 1$ quando o dia t, o dia anterior e o dia retrasado ficaram, todos, acima do P90 da sua época. A persistência importa porque o organismo consegue se recuperar entre dias quentes isolados, mas não numa sequência deles.

Noites quentes e chuva extrema. O mesmo critério se aplica à mínima noturna (a menor temperatura entre 18 h e 6 h), com P90 e P95 calculados na base disponível da estação A201 (2003–2020). Na precipitação, o limiar é o P95 *dos dias com chuva*, pela razão explicada na Seção 4.6.

7 Regressão quantílica e QGAM

7.1 Por que modelar quantis e não a média

A regressão comum descreve como a *média* de Y muda com uma variável x. Na saúde, porém, o que importa são os *dias extremos*. A média da temperatura pode subir 0,2 °C por década enquanto os dias mais quentes (o quantil 0,95) sobem 0,5 °C. Nesse caso os extremos aquecem mais rápido, e olhar só a média esconde isso.

A regressão quantílica descreve diretamente como um quantil de Y muda com x. Escreve-se $Q_p(Y \mid x)$ para o quantil de ordem p de Y entre os casos com covariável igual a x.

7.2 Que valor "resume melhor" os dados?

A chave da regressão quantílica é uma pergunta simples: se for preciso escolher um único número q para representar um conjunto de dados, qual escolher? A resposta depende de *como se penalizam os erros*.

Erro quadrático leva à média. Se o custo de errar por $y - q$ é $(y - q)^2$, o melhor q é a média. Basta derivar $\sum_i (y_i - q)^2$ em relação a q e igualar a zero: $-2\sum_i (y_i - q) = 0$, ou seja, $q = \bar{y}$.

Erro absoluto leva à mediana. Se o custo é $|y - q|$, o melhor q é a mediana.

Exemplo 7.1. Com os dados $\{1, 2, 10\}$, a média é 4,33 e a mediana é 2. A soma dos erros absolutos é $|1-2| + |2-2| + |10-2| = 9$ com $q = 2$, e $3{,}33 + 2{,}33 + 5{,}67 = 11{,}33$ com $q = 4{,}33$. A mediana ganha. Ela também não é "puxada" pelo valor extremo 10, ao contrário da média.

Erro assimétrico leva a um quantil. E se errar para um lado custar mais que errar para o outro?

Definição 7.2. Para $p \in (0, 1)$, a *função check* é

$$\rho_p(u) = u\,\big(p - \mathbb{I}(u < 0)\big) = \begin{cases} p\,u, & \text{se } u \geq 0 \text{ (observado acima de } q), \\ (1-p)\,|u|, & \text{se } u < 0 \text{ (observado abaixo de } q). \end{cases}$$

Em palavras

Com $p = 0{,}9$, cada grau em que o observado fica *acima* de q custa 0,9, e cada grau em que fica *abaixo* custa só 0,1. Um erro de $+2$ °C custa 1,8; um erro de -2 °C custa 0,2.
Como ficar abaixo de um ponto observado é caro, o melhor q sobe até que só restem 10% dos dados acima dele. Esse ponto é justamente o quantil 0,9. O nome "check" vem do formato do gráfico de ρ_p, parecido com o sinal de visto (✓). Com $p = 0{,}5$, os dois lados custam o mesmo, $\rho_{0,5}(u) = |u|/2$, e volta-se à mediana.

Proposição 7.3. *Se Y tem FDA F contínua, a função $q \mapsto \mathbb{E}[\rho_p(Y-q)]$ é convexa e atinge o mínimo em $q = F^{-1}(p)$.*

Relembrando: derivada e convexidade

Uma função é *convexa* quando tem forma de "tigela": qualquer segmento que liga dois pontos do gráfico fica acima do gráfico. Uma função derivável é convexa quando sua derivada é não decrescente. Numa função convexa, o ponto onde a derivada vale zero é o mínimo global.

Demonstração. O custo esperado divide-se entre os valores de Y abaixo de q e os acima de q:

$$\mathbb{E}[\rho_p(Y-q)] = (p-1)\int_{-\infty}^{q}(y-q)\,dF(y) + p\int_{q}^{\infty}(y-q)\,dF(y).$$

Derivando cada integral em relação a q (regra de Leibniz),

$$\frac{d}{dq}\int_{-\infty}^{q}(y-q)\,dF(y) = -F(q), \qquad \frac{d}{dq}\int_{q}^{\infty}(y-q)\,dF(y) = -\big(1-F(q)\big).$$

Logo

$$\frac{d}{dq}\mathbb{E}[\rho_p(Y-q)] = -(p-1)F(q) - p\big(1-F(q)\big) = F(q) - p.$$

Como F é não decrescente, a derivada também é, e a função é convexa. A derivada se anula quando $F(q) = p$, isto é, em $q = F^{-1}(p)$. □

Em palavras

A derivada $F(q) - p$ mostra o mecanismo. Enquanto menos de p da probabilidade está abaixo de q, a derivada é negativa e vale a pena aumentar q. Quando mais de p está abaixo, a derivada é positiva e vale a pena diminuir. O equilíbrio está no quantil de ordem p. É o análogo, para quantis, do fato de que a média minimiza o erro quadrático.

7.3 Regressão quantílica linear

Koenker & Bassett (1978) trocaram o número q por uma reta que depende das covariáveis:

$$\hat{\boldsymbol{\beta}}(p) = \arg\min_{\boldsymbol{\beta}} \sum_{t=1}^{n} \rho_p\big(y_t - \mathbf{x}_t^\top \boldsymbol{\beta}\big), \qquad Q_p(Y \mid \mathbf{x}) = \mathbf{x}^\top \boldsymbol{\beta}(p).$$

Relembrando: notação vetorial

$\mathbf{x}_t^\top \boldsymbol{\beta}$ é uma forma compacta de escrever $\beta_0 + \beta_1 x_{t1} + \cdots + \beta_k x_{tk}$. O símbolo $\arg\min$ significa "o valor de $\boldsymbol{\beta}$ que torna a soma a menor possível".

Não há fórmula fechada para $\hat{\boldsymbol{\beta}}(p)$, como há na regressão por mínimos quadrados. O problema é resolvido numericamente por programação linear, com métodos de pontos interiores (o `method = "fn"` do pacote `quantreg` do R).

Interpretação. $\beta_1(p)$ é *quanto o quantil p de Y muda quando x aumenta uma unidade*. Cada p tem seus próprios coeficientes.

Exemplo 7.4 (Hipotético)**.** Numa regressão da temperatura máxima no tempo, suponha que as inclinações estimadas sejam $\hat{\beta}_1(0{,}5) = 0{,}02$ e $\hat{\beta}_1(0{,}95) = 0{,}04$ °C por ano. A temperatura típica (mediana) sobe 0,2 °C por década, e os dias mais quentes sobem 0,4 °C por década. A cauda superior está se afastando do centro: a distribuição está se alargando para cima.

Quando os coeficientes mudam com p, como no exemplo, a variabilidade de Y muda com x. Isso se chama *heterocedasticidade*, e a regressão comum, que olha só a média, não a enxerga. A regressão quantílica também não supõe distribuição normal, é pouco afetada por valores extremos de y e herda a propriedade da Proposição 3.14. Santos (2012) desenvolve a inferência, os intervalos de confiança e a qualidade do ajuste desses modelos.

7.4 QGAM: regressão quantílica com curvas

O QGAM (Fasiolo et al., 2021) permite que parte do modelo seja uma *curva* estimada pelos dados, em vez de uma reta ou de uma forma imposta. O modelo do boletim, para a temperatura máxima T_t do dia t e o dia do ano d_t, é

$$Q_p(T_t) = \beta_0(p) + \beta_1(p)\, t + f_p(d_t), \qquad p \in \{0{,}05;\ 0{,}25;\ 0{,}50;\ 0{,}75;\ 0{,}95\}$$

Em palavras

Para cada quantil p, a temperatura tem três partes: um nível $\beta_0(p)$, uma tendência linear $\beta_1(p)\, t$ ao longo dos anos e uma curva sazonal $f_p(d_t)$ que descreve como a temperatura varia ao longo do ano. Cada quantil pode ter tendência e curva sazonal próprias.

Relembrando: spline

Uma *spline* é uma curva formada por pedaços de polinômios (em geral cúbicos) emendados de forma suave em pontos chamados *nós*. O nome vem da régua flexível que os desenhistas usavam para traçar curvas passando por pontos fixos. Na estatística, a spline é escrita como soma de funções simples, as *funções-base*: $f(x) = \sum_k \gamma_k b_k(x)$. Estimar a curva é estimar os pesos γ_k.

No boletim, f_p é uma spline cúbica *cíclica* com 20 funções-base. "Cíclica" significa que o fim da curva se emenda no começo: f_p em 31 de dezembro tem o mesmo valor e a mesma inclinação que em 1º de janeiro, como deve ser num ciclo anual.

A curva também é *penalizada*: o ajuste é punido quando a curva fica ondulada demais. Isso impede que ela acompanhe o ruído dos dados. A Seção 8 explica a penalização em detalhe.

O obstáculo técnico e a solução. A função check tem um "bico" em zero, onde não tem derivada. Os métodos que estimam curvas penalizadas dependem de derivadas. Fasiolo et al. (2021) contornaram isso trocando a função check por uma versão com o bico arredondado, a perda ELF (*extended log-F*):

$$\tilde{\rho}_p(u) = (p-1)\,\frac{u}{\sigma} + \lambda\, \log\!\left(1 + e^{\,u/(\lambda\sigma)}\right).$$

Quando λ tende a zero, o arredondamento desaparece e $\tilde{\rho}_p(u)$ volta a ser a função check (dividida por σ). O parâmetro σ, chamado de *taxa de aprendizado*, é calibrado para que, por exemplo, cerca de 95% dos dados fiquem de fato abaixo da curva do quantil 0,95.

Por que QGAM e não senos e cossenos. O modelo anterior do boletim descrevia a sazonalidade com senos e cossenos de período anual. Isso impõe uma curva simétrica, com a mesma forma de subida e de descida. A spline cíclica deixa os dados mostrarem a forma real do ciclo.

Relembrando: validação cruzada

Para saber se um modelo prevê bem, não basta medir o erro nos dados usados para ajustá-lo: o modelo pode ter "decorado" esses dados. Na *validação cruzada*, separa-se uma parte dos dados, ajusta-se o modelo com o resto e mede-se o erro na parte separada. Repete-se o processo para cada parte. Em séries temporais, as partes são *blocos de anos*, porque dias vizinhos são parecidos e separá-los um a um daria uma avaliação otimista.

Em Belém

Na validação cruzada por blocos de seis anos, o QGAM teve perda check fora da amostra igual ou ligeiramente menor que a do modelo com senos e cossenos (ganho de 0,1% a 0,5% nos quantis 0,05, 0,50 e 0,95). Um termo de interação entre ano e dia do ano, que permitiria ao ciclo anual mudar de forma ao longo dos anos, *piorou* a previsão (perda de 0,6% a 4,0%) e foi descartado. Um modelo mais complexo nem sempre prevê melhor.

Cuidado

Cruzamento de quantis. Cada quantil é ajustado separadamente. Nada garante que a curva do quantil 0,95 fique sempre acima da curva do quantil 0,75. Se, em algum dia, $Q_{0,95}$ ficar abaixo de $Q_{0,75}$, os resultados são incoerentes, porque um quantil maior nunca pode ser menor. É preciso verificar isso depois do ajuste. No boletim não houve cruzamentos.

8 MLG, GAM e diagramas de controle

8.1 Por que não usar a regressão linear comum para contagens

A regressão linear comum supõe que Y tem distribuição normal, com variância constante. Contagens de casos e óbitos não se comportam assim:

- são números inteiros e não negativos;
- têm distribuição assimétrica quando a média é baixa;
- variam mais quando a média é maior: uma semana com média de 100 casos oscila mais, em números absolutos, que uma semana com média de 5.

O modelo linear generalizado (MLG) resolve isso.

8.2 O modelo linear generalizado

Relembrando: distribuição de Poisson

É a distribuição clássica para contagens de eventos raros num intervalo de tempo:

$$\mathbb{P}(Y = y) = \frac{e^{-\mu}\mu^y}{y!}, \qquad y = 0, 1, 2, \ldots$$

Sua média e sua variância são iguais a μ.

Um MLG (Paula, 2013, cap. 1) tem três componentes:

1. **Componente aleatório.** A distribuição de Y_t pertence à *família exponencial*, um grupo que inclui a normal, a Poisson, a binomial e a gama:

   $$f(y; \theta, \phi) = \exp\left\{\frac{y\theta - b(\theta)}{\phi} + c(y, \phi)\right\}, \qquad \mathbb{E}(Y) = \mu, \quad \mathrm{Var}(Y) = \phi\, V(\mu).$$

   Não é preciso decorar essa fórmula. O importante é a última parte: em toda essa família, a variância é uma função $V(\mu)$ da média, multiplicada por um parâmetro de dispersão ϕ. Na Poisson, $V(\mu) = \mu$ e $\phi = 1$. (Paula, 2013, usa ϕ como parâmetro de *precisão*, o inverso do usado aqui.)

2. **Componente sistemático.** As covariáveis entram numa combinação linear $\eta_t = \beta_0 + \beta_1 x_{t1} + \ldots$, chamada *preditor linear*.

3. **Função de ligação.** Liga a média ao preditor: $g(\mu_t) = \eta_t$.

Em palavras

Por que uma função de ligação? A média de uma contagem precisa ser positiva, mas $\beta_0 + \beta_1 x$ pode dar qualquer número, inclusive negativo. Aplicando o logaritmo à média, $\log \mu_t = \eta_t$, a média fica $\mu_t = e^{\eta_t}$, que é sempre positiva.

Para contagens, o ponto de partida é Poisson com ligação logarítmica:

$$Y_t \sim \mathrm{Poisson}(\mu_t), \qquad \log \mu_t = \log N_t + \beta_0 + \beta_1 x_t.$$

Offset. O termo $\log N_t$ (o logaritmo da população) entra com coeficiente fixo igual a 1, sem ser estimado. Chama-se *offset*. Passando-o para o outro lado, $\log(\mu_t / N_t) = \beta_0 + \beta_1 x_t$: o modelo descreve a *taxa* de casos por habitante, e não a contagem bruta.

Exemplo 8.1. O distrito A tem 100 mil habitantes e 20 casos; o distrito B tem 300 mil habitantes e 30 casos. B tem mais casos, mas a taxa de A é 20 por 100 mil e a de B, 10 por 100 mil. O offset faz o modelo comparar taxas, e não contagens.

Risco relativo. Com ligação log, os coeficientes viram *razões*:

$$\mathrm{RR} = \frac{\mu(x+1)}{\mu(x)} = e^{\beta_1}.$$

Com $\beta_1 = 0{,}03$, cada unidade a mais de x multiplica a contagem esperada por $e^{0{,}03} \approx 1{,}03$, isto é, 3% a mais. Cinco unidades a mais multiplicam por $e^{0{,}15} \approx 1{,}16$.

8.3 Verossimilhança

Relembrando: verossimilhança

A *verossimilhança* é a probabilidade dos dados observados, vista como função dos parâmetros. Para cada valor possível de $\boldsymbol{\beta}$, ela responde: se este fosse o valor verdadeiro, qual seria a chance de observar exatamente estes dados? O *estimador de máxima verossimilhança* é o valor de $\boldsymbol{\beta}$ que torna os dados observados mais prováveis. Por conveniência, trabalha-se com o logaritmo da verossimilhança, $\ell(\boldsymbol{\beta})$.

8.4 Superdispersão

A Poisson exige que a variância seja igual à média. Dados de saúde costumam variar mais que isso, porque os casos não são independentes (há surtos e transmissão) e porque a população não é homogênea. Esse excesso se chama *superdispersão*. Ignorá-lo produz erros-padrão pequenos demais e conclusões confiantes demais. Há duas soluções usuais:

- **Quase-Poisson** (Wedderburn, 1974): supõe $\operatorname{Var}(Y_t) = \phi\,\mu_t$, com ϕ estimado pelos dados:

$$\hat{\phi} = \frac{1}{n-q}\sum_{t=1}^{n}\frac{(y_t-\hat{\mu}_t)^2}{\hat{\mu}_t},$$

  em que q é o número de parâmetros. As estimativas de $\boldsymbol{\beta}$ são as mesmas da Poisson; os erros-padrão são multiplicados por $\sqrt{\hat{\phi}}$. Com $\hat{\phi} = 2{,}5$, eles aumentam cerca de 58%. A quase-Poisson especifica só a média e a variância, não uma distribuição completa.

- **Binomial negativa**: supõe $\operatorname{Var}(Y_t) = \mu_t + \mu_t^2/\theta$. Com $\mu = 10$ e $\theta = 5$, a variância é $10 + 20 = 30$, o triplo da Poisson. É uma distribuição completa, o que permite simular contagens, algo necessário para os intervalos de predição dos diagramas.

8.5 GAM: quando a relação é uma curva

No MLG, o preditor muda linearmente com x. A incidência de muitas doenças ao longo do ano, porém, sobe e desce. O GAM (Hastie & Tibshirani, 1990; Wood, 2017) troca termos lineares por *curvas suaves* estimadas pelos dados:

$$\log \mu_t = \log N_t + \beta_0 + f(x_t), \qquad f(x) = \sum_{k=1}^{K}\gamma_k\, b_k(x).$$

Como f é uma spline (soma de funções-base com pesos γ_k), o GAM é um MLG com muitos coeficientes.

Penalização. Com muitas funções-base, a curva pode passar por quase todos os pontos e seguir o ruído. A solução é maximizar a verossimilhança *com uma punição pela ondulação*:

$$\hat{\boldsymbol{\gamma}} = \arg\max_{\boldsymbol{\gamma}}\left\{\ell(\boldsymbol{\gamma}) - \lambda\int f''(x)^2\,dx\right\}.$$

Em palavras

A segunda derivada f'' mede a *curvatura*: é zero numa reta e grande numa curva que muda de direção bruscamente. A integral soma essa curvatura ao longo de toda a curva. O parâmetro λ regula o equilíbrio:

- com λ muito grande, qualquer curvatura é cara, e f vira uma reta;
- com λ perto de zero, não há punição, e f segue os dados de perto, inclusive o ruído.

O valor de λ não é escolhido à mão: os dados o determinam por REML (máxima verossimilhança restrita) ou por GCV (validação cruzada generalizada), que procuram o equilíbrio entre ajuste e suavidade.

Graus de liberdade efetivos (edf). Resumem a complexidade da curva ajustada. Um edf de 1 indica uma reta; um edf de 5 indica uma curva com a flexibilidade de cerca de cinco parâmetros. Um edf próximo do número de funções-base indica que a curva usou quase toda a flexibilidade disponível, e talvez valha a pena aumentá-lo.

Spline cíclica. Para a semana epidemiológica s (de 1 a 52), exige-se

$$f(1) = f(52), \qquad f'(1) = f'(52), \qquad f''(1) = f''(52).$$

A curva termina no mesmo valor, com a mesma inclinação e a mesma curvatura com que começa, e não há salto artificial na virada do ano.

8.6 O diagrama de controle do boletim

O *canal endêmico* clássico define o esperado de cada semana pelos quartis, ou pela média mais ou menos dois desvios-padrão, dos anos anteriores. Ele tem três problemas: ignora a tendência, depende da escolha dos anos e fica instável com séries curtas. O boletim usa um GAM binomial negativo:

$$\boxed{Y_t \sim \mathrm{BN}(\mu_t, \theta), \qquad \log \mu_t = \beta_0 + f_1(\mathrm{SE}_t) + \beta_1 \, t \, [\, + \log N_t \,]}$$

- $f_1(\mathrm{SE}_t)$: curva cíclica da semana epidemiológica, que descreve a sazonalidade;
- $\beta_1 t$: tendência linear, que capta aumento ou queda de longo prazo;
- $\log N_t$: offset populacional, quando a população está disponível (Bhaskaran et al., 2013).

Deixa-um-ano-fora. O esperado de cada ano é previsto por um modelo ajustado *sem* esse ano. Se o ano entrasse no ajuste, um surto inflaria o próprio esperado e acabaria escondido.

Relembrando: intervalo de confiança e intervalo de predição

- O *intervalo de confiança* (IC) de μ_t diz onde está a *média* esperada da semana. Reflete só a incerteza sobre os parâmetros.
- O *intervalo de predição* (IP) diz onde deve cair a *contagem observada* da semana. Soma a incerteza dos parâmetros à variação natural das contagens em torno da média.

Para julgar se uma contagem observada é anormal, o certo é o IP, que é mais largo. Usar o IC geraria alarmes falsos demais.

Intervalo de predição por simulação. Um procedimento usual é o método de Monte Carlo, que consiste em repetir sorteios aleatórios muitas vezes e olhar a distribuição dos resultados:

1. sortear valores dos parâmetros a partir da distribuição aproximada das estimativas, $\boldsymbol{\beta}^{(b)} \sim \mathcal{N}\big(\hat{\boldsymbol{\beta}}, \hat{\mathbf{V}}_{\boldsymbol{\beta}}\big)$, para $b = 1, \ldots, B$;
2. com cada sorteio, calcular a média $\mu_t^{(b)}$ e sortear uma contagem $y_t^{(b)} \sim \mathrm{BN}\big(\mu_t^{(b)}, \hat{\theta}\big)$;
3. tomar os quantis 0,025 e 0,975 das B contagens sorteadas.

O passo 1 traz a incerteza dos parâmetros; o passo 2, a variação natural das contagens.

Gatilhos. Os gatilhos usam a razão entre observado e esperado, $R_t = y_t / \hat{\mu}_t$. Uma razão de 1,5 significa 50% mais casos que o esperado. O boletim compara essa razão em três situações: semanas sem episódio de calor, semanas com episódio e até sete dias depois do episódio.

9 DLNM: efeitos não lineares e defasados

9.1 Motivação

A relação entre temperatura e óbitos tem duas características que um MLG simples não captura.

Não linearidade. O risco não cresce em linha reta com a temperatura. Ele costuma ter um ponto mínimo e subir nas pontas (formato de U), ou subir só de um lado (formato de J).

Defasagem. Um dia muito quente pode causar óbitos no mesmo dia, dois dias depois ou uma semana depois. O intervalo entre a exposição e o efeito chama-se *defasagem* (em inglês, *lag*). Pode haver também *antecipação* (*harvesting*): o calor adianta em alguns dias a morte de pessoas já muito frágeis, e o excesso de óbitos é seguido de um déficit nos dias seguintes. Olhar só o mesmo dia superestimaria o efeito; olhar só um dia distante o perderia.

9.2 Modelo de defasagem distribuída

A forma mais simples de incluir defasagens é pôr no modelo a temperatura de hoje e a dos dias anteriores, até uma defasagem máxima L:

$$\log \mu_t = \alpha + \sum_{\ell=0}^{L} \beta_\ell \, x_{t-\ell}.$$

Aqui $x_{t-\ell}$ é a temperatura de ℓ dias atrás, e β_ℓ é o efeito dela sobre os óbitos de hoje.

Em palavras

O problema é que a temperatura de hoje é muito parecida com a de ontem e a de anteontem. Quando as variáveis de um modelo são muito correlacionadas entre si, o modelo não consegue separar o efeito de cada uma (*colinearidade*), e as estimativas oscilam de forma errática. Com $L = 14$, seriam 15 coeficientes instáveis.

A solução é supor que o efeito muda *suavemente* com a defasagem, e escrever os β_ℓ como uma spline na dimensão da defasagem:

$$\beta_\ell = \sum_{k=1}^{m} \eta_k \, c_k(\ell).$$

Com poucas funções-base c_k, estimam-se m coeficientes em vez de 15.

9.3 Base cruzada: as duas dimensões juntas

Gasparrini, Armstrong & Kenward (2010) permitiram curvas nas duas dimensões ao mesmo tempo: na temperatura (para captar o formato em U ou J) e na defasagem. A função

$$f(x, \ell) = \sum_{j=1}^{v} \sum_{k=1}^{m} b_j(x) \, c_k(\ell) \, \theta_{jk}$$

dá o efeito, sobre os óbitos de hoje, de uma temperatura x ocorrida há ℓ dias. As funções b_j são a base na temperatura e as c_k, a base na defasagem.

Em palavras

Imagine uma superfície, como um mapa de relevo. Um eixo é a temperatura; o outro, quantos dias atrás ela ocorreu; a altura é o efeito sobre o risco. A base cruzada é a forma de descrever essa superfície com poucos parâmetros θ_{jk}, combinando as curvas da temperatura com as curvas da defasagem.

O efeito total sobre o dia t soma as contribuições de todas as temperaturas dos 15 dias anteriores:

$$s(x_t) = \sum_{\ell=0}^{L} f(x_{t-\ell}, \ell) = \sum_{j=1}^{v} \sum_{k=1}^{m} z_{tjk} \, \theta_{jk}, \qquad z_{tjk} = \sum_{\ell=0}^{L} b_j(x_{t-\ell}) \, c_k(\ell).$$

As variáveis z_{tjk} são calculadas a partir da série de temperaturas e formam a *base cruzada*. Como $s(x_t)$ é uma soma de variáveis multiplicadas por coeficientes, o modelo continua sendo um MLG comum, ajustado pelos mesmos métodos.

9.4 O modelo do boletim

$$\boxed{\log \mathbb{E}(Y_t) = \alpha + \text{cb}(T_t, \ldots, T_{t-14}) + \text{ns}(t) + \text{DS}_t, \qquad \text{Var}(Y_t) = \phi\, \mu_t}$$

- Y_t: número de óbitos no dia t;
- cb: base cruzada da temperatura máxima, com spline natural na temperatura (nós nos percentis 10, 75 e 90) e spline natural na defasagem (três nós em escala logarítmica, mais próximos nos primeiros dias, quando o efeito muda mais rápido);
- $\text{ns}(t)$: spline natural do tempo com 7 graus de liberdade por ano, que absorve a sazonalidade e a tendência de longo prazo;
- DS_t: indicadoras do dia da semana, porque o registro de óbitos varia ao longo da semana;
- $\text{Var}(Y_t) = \phi\, \mu_t$: quase-Poisson, para acomodar a superdispersão;
- período de 2015 a agosto de 2026, excluindo março de 2020 a dezembro de 2021 (pandemia de COVID-19).

Relembrando: confundimento

Um *fator de confundimento* é uma variável associada tanto à exposição quanto ao desfecho, capaz de criar uma associação aparente entre os dois. Temperatura e óbitos têm ciclos anuais próprios: no inverno amazônico há mais doenças respiratórias e a temperatura é um pouco mais baixa. Sem controlar a estação, o modelo poderia atribuir à temperatura um efeito que é da época do ano. O termo $\text{ns}(t)$ remove esses ciclos e as mudanças lentas, e o modelo passa a comparar dias próximos no tempo, que diferem principalmente pela temperatura.

9.5 Como ler os resultados

Temperatura de mínima mortalidade (TMM). É a temperatura em que o risco acumulado é mais baixo, procurada entre os percentis 1 e 99 da temperatura máxima:

$$\text{TMM} = \underset{x \in [P_1, P_{99}]}{\arg\min} \sum_{\ell=0}^{L} f(x, \ell).$$

Ela serve de *referência*: todos os riscos relativos comparam uma temperatura com a TMM. Procura-se entre P1 e P99 porque, nas pontas extremas, há poucos dados e a curva é instável.

Risco relativo acumulado. Com $x_0 = \text{TMM}$,

$$\text{RR}(x) = \exp\left\{ \sum_{\ell=0}^{L} \left[f(x, \ell) - f(x_0, \ell) \right] \right\}.$$

Em palavras

Responde à pergunta: *um dia com temperatura x, comparado a um dia na TMM, multiplica o risco total de óbito dos 15 dias seguintes por quanto?* Um RR de 1,14 significa 14% mais óbitos; um RR de 1 significa nenhuma diferença.

Fração atribuível. Na perspectiva retrospectiva (Gasparrini & Leone, 2014), com $\beta_{x,\ell} = f(x,\ell) - f(x_0,\ell)$, o número de óbitos do dia t atribuível às temperaturas anteriores acima da TMM é

$$\mathrm{AN}_t = y_t \left[1 - \exp\left(-\sum_{\ell=0}^{L} \beta_{x_{t-\ell},\ell}\right)\right], \qquad \mathrm{FA} = \frac{\sum_t \mathrm{AN}_t}{\sum_t y_t}.$$

Em palavras

A fração atribuível estima *que parte dos óbitos do período não teria ocorrido se a temperatura tivesse ficado na TMM*. "Retrospectiva" significa que, para os óbitos de cada dia, olha-se para trás: quanto as temperaturas dos 15 dias anteriores contribuíram. Uma FA de 0,52% equivale a cerca de 5 óbitos em cada 1.000.

O intervalo de confiança da FA é obtido por Monte Carlo: sorteiam-se mil conjuntos de parâmetros $\boldsymbol{\theta}^{(b)} \sim \mathcal{N}(\hat{\boldsymbol{\theta}}, \hat{\mathbf{V}})$, calcula-se a FA com cada um e tomam-se os percentis 2,5 e 97,5.

Relembrando: intervalo de confiança de 95%

É um intervalo calculado por um procedimento que, se fosse repetido em muitas amostras, conteria o valor verdadeiro em 95% das vezes. Se o IC de um RR contém o 1, os dados são *compatíveis* com ausência de efeito, mas também com efeitos de certo tamanho. Isso não prova que o efeito é zero.

Em Belém

Com 84.444 óbitos por causas naturais, o RR no P99 da temperatura máxima foi 1,03 (IC95%: 0,97 a 1,10). Nas doenças cardiovasculares foi 1,14 (0,98 a 1,31), com FA de 0,52% ($-0{,}06$ a 0,98). Nas doenças respiratórias, o mínimo ficou no limite superior da faixa de busca, sem um mínimo no interior.
A amplitude térmica de Belém é pequena: a temperatura máxima fica quase sempre entre 30 e 36 °C. Com pouca variação na exposição, há pouca informação para estimar o efeito, e os intervalos ficam largos. Um intervalo que inclui o 1 **não demonstra ausência de associação**: indica que os dados não têm poder estatístico suficiente para detectá-la. Em cidades com faixa de temperatura maior, o mesmo modelo dispõe de muito mais informação.

Cuidado

O DLNM descreve uma associação em dados agregados por dia (um estudo ecológico de séries temporais). Ele não prova causalidade nem permite falar do risco de uma pessoa específica. Os resultados dependem de escolhas como a posição dos nós, a defasagem máxima e os graus de liberdade de $\mathrm{ns}(t)$. Por isso é recomendável repetir a análise variando essas escolhas (análise de sensibilidade).

10 Índice de vulnerabilidade territorial

Um índice composto resume vários indicadores (renda, saneamento, proporção de idosos etc.) num único número por distrito. O problema é que os indicadores têm unidades e escalas diferentes. A *normalização mín-máx* coloca todos na escala de 0 a 1:

$$z_{ik} = \frac{x_{ik} - \min_i x_{ik}}{\max_i x_{ik} - \min_i x_{ik}},$$

em que i é o distrito e k o indicador. Cada indicador é orientado de modo que valores maiores signifiquem mais vulnerabilidade.

Exemplo 10.1. Três distritos têm 20%, 50% e 80% de domicílios sem esgotamento adequado. O mínimo é 20 e o máximo é 80, então os valores normalizados são $(20-20)/60 = 0$, $(50-20)/60 = 0{,}5$ e $(80-20)/60 = 1$.

O índice é a média ponderada dos indicadores normalizados:

$$\mathrm{IVT}_i = \sum_{k=1}^{K} w_k \, z_{ik}, \qquad w_k = \frac{1}{K}.$$

Cuidado

- **Os pesos são uma escolha, não uma estimativa.** Pesos iguais dizem que todos os indicadores importam o mesmo, o que é uma decisão. Por isso o boletim repete o cálculo em quatro cenários de pesos: se a ordem dos distritos se mantém, o resultado não depende muito da escolha.
- **A normalização é sensível a valores extremos.** Um único distrito muito atípico define o mínimo ou o máximo e comprime todos os outros numa faixa estreita.
- **O índice é relativo.** Um distrito com valor 0 é o menos vulnerável *entre os de Belém*, não um distrito sem vulnerabilidade.

11 Glossário

Amostra. Conjunto de dados observados, usado para estimar características desconhecidas.

Anomalia. Diferença entre o valor observado e a normal climatológica do período.

Autocorrelação. Correlação de uma série com ela mesma em instantes anteriores; um mês quente tende a vir depois de outro mês quente.

Base (funções-base). Funções simples cuja soma ponderada forma uma curva, como uma spline.

Base cruzada. Combinação de uma base na exposição com uma base na defasagem, usada no DLNM.

Colinearidade. Correlação forte entre variáveis explicativas, que impede separar seus efeitos.

Confundimento. Associação aparente entre exposição e desfecho criada por uma terceira variável ligada às duas.

Consistência. Propriedade de um estimador que se aproxima do valor verdadeiro quando a amostra cresce.

Continuidade à direita. Ao se aproximar de um ponto pela direita, a função tende ao seu valor no ponto.

Convexa (função). Função em forma de "tigela"; o ponto de derivada zero é o mínimo.

Defasagem (lag). Intervalo de tempo entre a exposição e o efeito.

Desvio-padrão. Raiz quadrada da variância; mede a dispersão na unidade da variável.

edf. Graus de liberdade efetivos; mede a complexidade de uma curva ajustada.

Erro absoluto médio (MAE). Média das distâncias, sem sinal, entre valores verdadeiros e estimados.

Esperança. Valor médio de uma variável aleatória a longo prazo.

Estatísticas de ordem. Os dados da amostra ordenados do menor para o maior.

Estimador. Regra que usa a amostra para aproximar uma característica desconhecida.

FDA. Função de distribuição acumulada, $F(x) = \mathbb{P}(X \le x)$.

FDA empírica. Proporção de observações menores ou iguais a x.

Fração atribuível. Parte dos casos que não teria ocorrido sem a exposição acima da referência.

Função check. Função de perda assimétrica cujo minimizador é um quantil.

Função de ligação. Função que liga a média ao preditor linear num MLG, como o logaritmo.

Heterocedasticidade. Variância que muda conforme as covariáveis.

Ínfimo. Maior número menor ou igual a todos os elementos de um conjunto.

Intervalo de confiança. Intervalo para um parâmetro, como a média esperada.

Intervalo de predição. Intervalo para uma nova observação; é mais largo que o de confiança.

Inversa generalizada. $F^{-1}(u) = \inf\{x : F(x) \ge u\}$; a função quantil.

Monte Carlo. Aproximação de uma distribuição pela repetição de muitos sorteios aleatórios.

Normal climatológica. Média de 30 anos de referência para cada mês ou dia.

Offset. Termo com coeficiente fixo em 1, usado para modelar taxas em vez de contagens.

Penalização. Punição à ondulação de uma curva, para evitar que ela siga o ruído.

Quantil de ordem u. Valor que deixa a proporção u dos dados abaixo dele.

Risco relativo. Razão entre o risco num nível de exposição e o risco na referência.

Spline. Curva formada por pedaços de polinômios emendados de forma suave.

Superdispersão. Variância das contagens maior que a média.

TMM. Temperatura de mínima mortalidade; referência dos riscos relativos no DLNM.

Validação cruzada. Avaliação de um modelo em dados que não foram usados para ajustá-lo.

Variância. Média dos quadrados dos desvios em relação à média.

Verossimilhança. Probabilidade dos dados observados vista como função dos parâmetros.

Viés. Diferença entre a média de um estimador e o valor verdadeiro.

12 Exercícios

1. Prove o Lema 3.4 sem consultar a demonstração. Em que passo a continuidade à direita é usada?

2. Seja X com FDA $F(x) = 1 - e^{-2x}$, $x \ge 0$. Encontre $F^{-1}(u)$ e descreva como gerar valores de X a partir de $U \sim \mathcal{U}(0,1)$.

3. Mostre que, se $X \sim \text{Poisson}(2)$, $F(X)$ não tem distribuição uniforme. Relacione o resultado com o tratamento da precipitação no mapeamento quantílico.

4. Para a amostra $\{29{,}9;\ 30{,}6;\ 31{,}4;\ 32{,}2;\ 33{,}0\}$, calcule o quantil 0,8 pelos tipos 7 e 8 de Hyndman & Fan.

5. Prove a Proposição 3.14 usando o Lema 3.4.

6. Mostre que, no meio de uma lacuna ($w = 1/2$) e com $\rho = 0{,}6$, a interpolação linear reduz o desvio-padrão em cerca de 11%.

7. Refaça a demonstração da Proposição 7.3 e explique, em palavras, por que a derivada $F(q) - p$ leva ao quantil.

8. Explique por que, num diagrama de controle, o intervalo de predição deve ser mais largo que o intervalo de confiança de μ_t.

9. No DLNM, por que um RR com intervalo de confiança contendo 1 não autoriza afirmar que "o calor não afeta a mortalidade em Belém"?

Dicas e respostas

1. Separe as duas implicações. A continuidade à direita aparece na ida ($\Rightarrow$), para garantir que F no próprio quantil já é pelo menos u.

2. $F^{-1}(u) = -\frac{1}{2}\ln(1-u)$; gere U e calcule $X = -\frac{1}{2}\ln(1-U)$.

3. $F(X)$ só assume valores como $F(0) = e^{-2} \approx 0{,}135$ e $F(1) \approx 0{,}406$, com probabilidades positivas; uma uniforme não tem valores com probabilidade positiva. Com chuva, o zero tem probabilidade positiva, e o mesmo problema aparece.

4. $nu = 4$. Tipo 7: $m = 0{,}2$, $j = 4$, $\gamma = 0{,}2$, resultado 32,36. Tipo 8: $m = 0{,}6$, $j = 4$, $\gamma = 0{,}6$, resultado 32,68.

5. Mostre que $\{h(X) \le h(\xi)\}$ e $\{X \le \xi\}$ têm a mesma probabilidade quando h é crescente e use a definição de ínfimo.

6. $\mathrm{Var}(\tilde{Y}) = \sigma^2(1 + 0{,}6)/2 = 0{,}8\sigma^2$; o desvio-padrão é $\sqrt{0{,}8}\,\sigma \approx 0{,}894\,\sigma$, uma redução de cerca de 10,6%.

7. Ver o quadro "Em palavras" após a demonstração.

8. O intervalo de predição inclui a variação natural da contagem em torno da média, além da incerteza dos parâmetros.

9. Um IC que contém 1 indica falta de evidência, não evidência de ausência; com pouca amplitude térmica, o poder estatístico é baixo.

Referências

- Bhaskaran, K.; Gasparrini, A.; Hajat, S.; Smeeth, L.; Armstrong, B. (2013). Time series regression studies in environmental epidemiology. *International Journal of Epidemiology*, 42(4), 1187–1195.
- Casella, G.; Berger, R. L. (2002). *Statistical Inference*. 2. ed. Pacific Grove: Duxbury.
- Fasiolo, M.; Wood, S. N.; Zaffran, M.; Nedellec, R.; Goude, Y. (2021). Fast calibrated additive quantile regression. *Journal of the American Statistical Association*, 116(535), 1402–1412.
- Gasparrini, A.; Armstrong, B.; Kenward, M. G. (2010). Distributed lag non-linear models. *Statistics in Medicine*, 29(21), 2224–2234.
- Gasparrini, A.; Leone, M. (2014). Attributable risk from distributed lag models. *BMC Medical Research Methodology*, 14, 55.
- Gudmundsson, L.; Bremnes, J. B.; Haugen, J. E.; Engen-Skaugen, T. (2012). Downscaling RCM precipitation to the station scale using statistical transformations: a comparison of methods. *Hydrology and Earth System Sciences*, 16, 3383–3390.
- Hastie, T.; Tibshirani, R. (1990). *Generalized Additive Models*. London: Chapman & Hall.

- Hyndman, R. J.; Fan, Y. (1996). Sample quantiles in statistical packages. *The American Statistician*, 50(4), 361–365.
- Koenker, R.; Bassett, G. (1978). Regression quantiles. *Econometrica*, 46(1), 33–50.
- Koenker, R. (2005). *Quantile Regression*. Cambridge: Cambridge University Press.
- Morettin, P. A.; Toloi, C. M. C. (2006). *Análise de Séries Temporais*. 2. ed. São Paulo: Edgard Blücher.
- Panofsky, H. A.; Brier, G. W. (1968). *Some Applications of Statistics to Meteorology*. University Park: Pennsylvania State University.
- Paula, G. A. (2013). *Modelos de Regressão com Apoio Computacional*. São Paulo: IME-USP.
- Santos, B. R. (2012). *Modelos de Regressão Quantílica*. Dissertação (Mestrado em Estatística) – IME-USP, São Paulo.
- Serfling, R. J. (1980). *Approximation Theorems of Mathematical Statistics*. New York: Wiley.
- Wedderburn, R. W. M. (1974). Quasi-likelihood functions, generalized linear models, and the Gauss–Newton method. *Biometrika*, 61(3), 439–447.
- Wood, S. N. (2017). *Generalized Additive Models: An Introduction with R*. 2. ed. Boca Raton: CRC Press.